

---

Вы – менеджер компании Olist Store, которая всегда была на острие передовых технологий в области e-сом торговли. Но вы замечаете, что отзывы ваших клиентов на платформе -хуже чем у клиентов, а товары часто доставляются с опозданием

Ваша цель – взять реванш и доказать, что ваша компания не зря славится своими инновационными решениями. Вы решаете провести масштабное исследование исторических данных о продажах, товарах, селлерах и клиентах, чтобы предоставить вашим клиентам лучший сервис. Вы докажете, что вы главные в E-сом

В невероятной атмосфере высоких ставок и огромной ответственности за результат вам придется:

1. Провести анализ данных (EDA), чтобы разобраться, какие факторы влияют на калорийный расход.
2. Разработать машинную модель, которую трижды улучшить, доказывая, что вы движетесь в правильном направлении.
3. Создать интерактивный дашборд в DataLens для наглядной демонстрации операционных метрик руководству, здесь не нужно использовать результаты ML модели. Графики могут дублироваться с частью EDA, но давать оперативную информацию для принятия управленческих решений

Вы можете выбрать одну из проблем и построить ее решение, другой займется ваш коллега, не тратьте время на решение обоих.

---

## Структура данных

Данные для задания состоят из нескольких таблиц, из которых предстоит подготовить фичи для анализа (признаки по селлерам, товарам, особенностям оплаты).

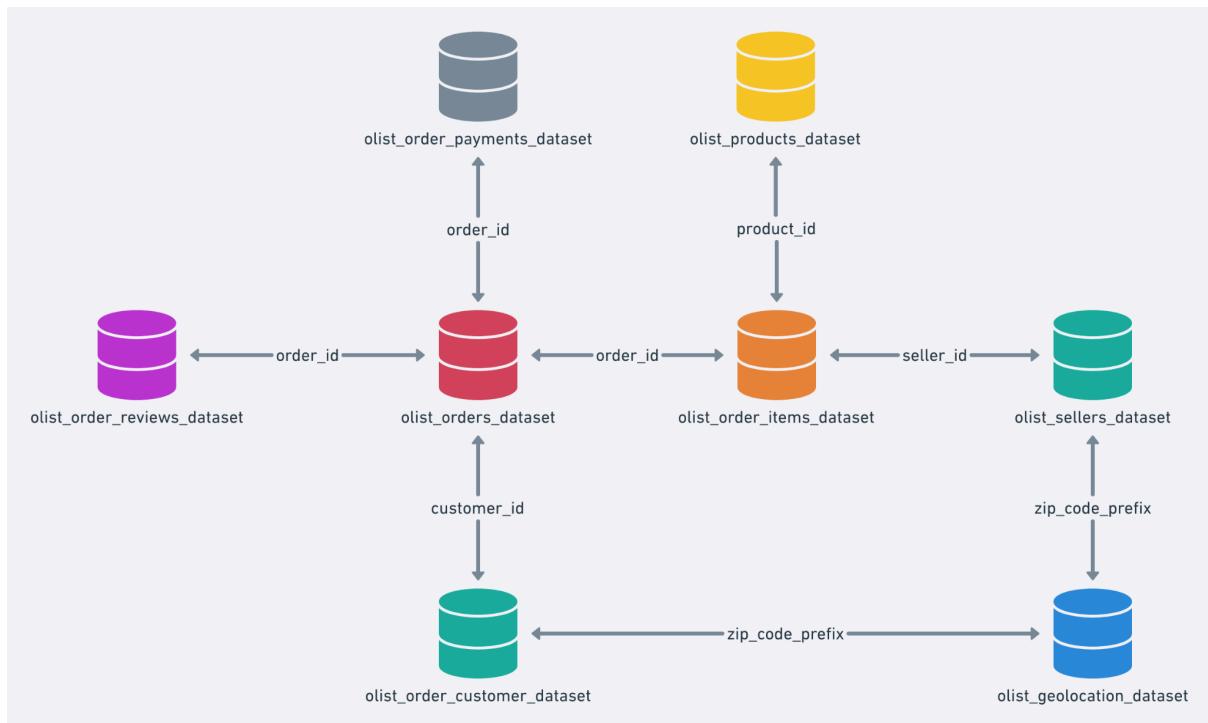
Таблицы придется объединить по соответствующем id в соответствии с вашим представлением о необходимом результате

Данные доступны по ссылке

[https://www.kaggle.com/datasets/olistbr/brazilian-e-commerce/data?select=olist\\_orders\\_data\\_set.csv](https://www.kaggle.com/datasets/olistbr/brazilian-e-commerce/data?select=olist_orders_data_set.csv)

## Таблицы:

1. olist\_orders описывает заказы товаров
2. olist\_order\_reviews описывает отзывы на заказы
3. olist\_order\_payments описывает способы оплаты и суммы в заказах
4. olist\_order\_items описывает состав заказов, кто продал, нужен для связи таблиц воедино
5. olist\_sellers описывает признаки селлеров
6. olist\_customer описывает признаки покупателям
7. olist\_order\_customer для связи покупателя и заказа
8. olist\_products описывает товары
9. olist\_geolocation содержит данные о локациях по зип\_кодам доставки



## Техническое задание

### Вариант 1

#### Часть 1. Exploratory Data Analysis (EDA)

##### Цель исследования

Выявить особенности заказов, на которые пользователи ставят низкие оценки в отзывах (review\_score 1-2 звезды).

## **Задачи**

### **1. Проверка данных:**

- Определите наличие пропущенных значений, выбросов и аномалий.
- Примите решение, как корректировать или учитывать эти пропуски и аномалии при дальнейшем анализе.

### **2. Анализ распределений:**

- Постройте графики распределения для числовых переменных
- Изучите распределение по категориальным переменным.

### **3. Корреляционный анализ:**

Исследуйте взаимосвязи между признаками.

- Используйте карту корреляций или аналогичный инструмент для визуализации.

### **4. Гипотезы и инсайты:**

- Сформулируйте предположения, какие характеристики присущи заказам с низкими отзывами.
- По возможности опишите сценарии оптимизации для сокращения количества негативных отзывов на платформе.

## **Ожидаемый результат**

- Читаемые и понятные графики, таблицы и статистика.
- Аналитический отчёт с основными выводами, гипотезами и рекомендациями для руководства, оформленный так, чтобы было ясно, что вы провели глубокий анализ и готовы к дальнейшим шагам.
- Должен содержать минимум 5 значимых для бизнеса вывода

## **Наводящие бизнес-вопросы**

- Какие факторы (скорость доставки, география, категория товара, цена, способ оплаты и т.п.) чаще всего связаны с оценками 1–2?
- Чем «хорошие» заказы (4–5 звёзд) отличаются от «плохих» (1–2)?

- Для каких сегментов (штаты / категории / продавцы) проблема особенно остра?
  - Какой профиль «рискованного» заказа, который с высокой вероятностью получит низкую оценку?
- 

## **Часть 2. Моделирование и Машинное Обучение**

### **Задача**

Создать инструмент для выявления заказов, по которым пользователи потенциально могут поставить низкие оценки (1-2) на раннем этапе

### **Обязательные требования**

- Ясное описание выбранной метрики качества (бизнес и ML метрикой) и почему с точки зрения бизнеса это важно.
  - Документирование всех этапов с пояснениями – от идей до финальных результатов.
  - Код в Jupyter Notebook или аналогичном формате с комментариями / проект в Orange с описаниями, куда может заглянуть любой коллега и понять логику.
  - Опишите в отчете, на какие метрики после запуска модели вы будете смотреть, контролируя, что модель функционирует нормально
- 

## **Часть 3. Создание Интерактивного Дашиборда**

### **Задача**

Создать интерактивный дашборд для оперативного контроля ситуации руководством. Можете здесь вывести те метрики из EDA, которые посчитаете необходимым мониторить наравне с целевой метрикой % / количества заказов с низкой оценкой

### **Требования к дашборду**

1. **Выведите ключевые метрики и их динамику**
2. **Фильтры для сегментации данных:**
3. **Визуализации:**

- Графики, диаграммы, таблицы – всё должно быть представлено наглядно и доступно даже для пользователей без технического бэкграунда.

## Ожидаемый результат

- Полноценный дашборд в Yandex DataLens.

## Вариант 2

### Часть 1. Exploratory Data Analysis (EDA)

#### Цель исследования

Выявить особенности заказов, которые доезжают с задержкой

#### Задачи

##### 1. Проверка данных:

- Определите наличие пропущенных значений, выбросов и аномалий.
- Примите решение, как корректировать или учитывать эти пропуски и аномалии при дальнейшем анализе.

##### 2. Анализ распределений:

- Постройте графики распределения для числовых переменных
- Изучите распределение по категориальным переменным.

##### 3. Корреляционный анализ:

Исследуйте взаимосвязи между признаками.

- Используйте карту корреляций или аналогичный инструмент для визуализации.

##### 5. Гипотезы и инсайты:

- Сформулируйте предположения, какие характеристики присущи заказам с задержкой.
- По возможности опишите сценарии оптимизации для сокращения количества заказов с задержкой.

## **Ожидаемый результат**

- Читаемые и понятные графики, таблицы и статистика.
- Аналитический отчёт с основными выводами, гипотезами и рекомендациями для руководства, оформленный так, чтобы было ясно, что вы провели глубокий анализ и готовы к дальнейшим шагам.
- Должен содержать минимум 5 значимых для бизнеса вывода

## **Наводящие бизнес-вопросы**

- В каких связках «продавец → регион клиента» чаще всего бывают задержки?
  - Как на задержку влияют типы товаров, вес/размер, стоимость, время покупки?
  - Есть ли продавцы или регионы, которые системно нарушают сроки?
  - Можно ли заранее предсказать, что заказ будет доставлен позже обещанного срока?
- 

## **Часть 2. Моделирование и Машинное Обучение**

### **Задача**

Разработать модель, позволяющую предсказать, что на этот товар потенциально может доехать с задержкой, чтобы команда могла принять меры по ее предотвращению / скорректировать срок доставки

### **Обязательные требования**

- Ясное описание выбранной метрики качества (бизнес и ML метрикой) и почему с точки зрения бизнеса это важно.
  - Документирование всех этапов с пояснениями – от идей до финальных результатов.
  - Код в Jupyter Notebook или аналогичном формате с комментариями / проект в Orange с описаниями, куда может заглянуть любой коллега и понять логику.
  - Опишите в отчете, на какие метрики после запуска модели вы будете смотреть, контролируя, что модель функционирует нормально
- 

## **Часть 3. Создание Интерактивного Дашборда**

## **Задача**

Создать интерактивный дашборд для оперативного контроля ситуации руководством. Можете здесь вывести те метрики из EDA, которые посчитаете необходимым мониторить наравне с целевой метрикой % / количества заказов с задержкой

## **Требования к дашборду**

- 1. Выведите ключевые метрики и их динамику**
- 2. Фильтры для сегментации данных:**
- 3. Визуализации:**
  - Графики, диаграммы, таблицы – всё должно быть представлено наглядно и доступно даже для пользователей без технического бэкграунда.

## **Ожидаемый результат**

- Полноценный дашборд в Yandex DataLens.
- 

## **Формат сдачи и дополнительные указания**

- 1. Единый отчёт**
  - Все этапы проекта (EDA, модель, дашборд) описываются последовательно в одном документе или ноутбуке.
  - Должна быть логика повествования: от постановки задачи до итогового представления решения.
- 2. Презентация и короткое видео**
  - На базе итогового отчёта подготовьте презентацию.
  - Запишите видео длительностью не более 10 минут, чтобы кратко показать основные инсайты анализа, дашборд, объяснить основные шаги проведенного анализа

- Указать обязанности каждого члена команды

### 3. **Документирование**

- Каждый график должен иметь подпись, поясняющую, что на нём изображено и какие выводы можно сделать.
- Код должен сопровождаться комментариями и объяснениями ключевых шагов.
- Если используете что-то сверх пройденного курса (дополнительные библиотеки, математические приёмы и т. д.), дайте ссылки или краткое описание.

### 4. **Из чего складывается оценка:**

- **40%:** отчет (презентация с EDA, описанием шагов, расчетные файлы)
- **60%:** защита проекта (отчетное видео с презентацией и дашбордом)

### 5. **Критерии оценивания**

- **До 3 баллов:** за качество EDA (глубина анализа, визуализации, проверка гипотез).
- **До 3 баллов:** за ML-пайплайн (масштабирование, feature engineering, подбор гиперпараметров) и демонстрацию улучшения метрик (3 итерации).
- **До 2 баллов:** за интерактивный дашборд (доступность, структурированность).
- **До 2 баллов:** за потенциальную пользу для бизнеса, применимость предложений по улучшению
- **Итого максимум 10 баллов.**

---

Удачи!