

Семинар 5

**Бизнес-аналитика и ИИ как инструмент эффективного
управления**

Что сегодня будем делать

- Потрогаем руками весь путь разработки модели
- Узнаем, на что непосредственно заказчикам модели стоит смотреть при её приемке
- С какими проблемами можно столкнуться при выводе модели в продакшн

Метрика хороша, но есть нюанс...

Предполагается, что на этапе постановки задачи разработчикам мы уже зафиксировали, какие ML-метрики являются правильными для решения бизнес-задачи

Почему ML-метрика может быть большой хотя фактически модель плохая:

- **Переобучение**

На тестовой выборке хорошие результаты, а на тренировочной еще сильно лучше → скорее всего модель будет нестабильной

- **Некорректное разбиение** на тренировочную и тестовую выборки

В качестве тестовой выборки использовался аномальный период, который не отражает естественную среду работы модели → модель не будет хорошо работать

- **"Лик"** в данных

Модель обучается с учетом информации о целевой переменной в признаках
→ модель не будет хорошо работать

Пример: при прогнозе оттока на следующий месяц одним из факторов брался флаг закрытого договора за последний месяц

Метрика хороша, но есть нюанс...

Предполагается, что на этапе постановки задачи разработчикам мы уже зафиксировали, какие ML-метрики являются правильными для решения бизнес-задачи

Кто виноват?	Что делать?
Переобучение	Использовать другие подходы к построению модели и проверять «разлет» метрик на тренировочной и тестовой выборке
Некорректное разбиение	Уточнять особенности разбиения данных на тренировочную и тестовую. Возможно подкорректировать разбиения
Лик в данных	Тщательно отнестись к оценке признаков, которые попали в модель. Добавить важные по бизнес-смыслу или сделать логические фильтры

Модельные риски

- **Применяем не на том, на чем обучались**

Смещение в данных. Естественные отличия = можно ожидать других результатов модели

Пример:

Рекламную кампанию проводили на конкретных клиентах (возможно они отбирались уже с определенными фильтрами) -> обучили на этом модель -> применяем на всех клиентов

- **”Drift” данных**

Изменение распределения данных, на которых работает модель

Пример:

Ключевая ставка растет -> среда меняется -> в новых условиях модель может затухнуть

- **“Concept Shift”**

Закономерности, которые выявила и использовала модель, устаревают

Пример:

Распределение признаков остается тем же, но поведение пользователей меняется